Эндогенность

инструментальные переменные

Проблема

Важное предположение классической линейной регрессии $Y = X\beta + \varepsilon$ - предположение **экзогенности** регрессоров, то есть некоррелированности регрессоров и случайной ошибки:

$$\operatorname{cov}(X,\varepsilon) = 0$$
 $E(\varepsilon \mid X) = 0$ $\lim_{n \to \infty} \frac{X'\varepsilon}{n} = 0$

Когда регрессоры полагаются детерминированными, это предположение удовлетворяется автоматически, если же регрессоры стохастичны (как в примерах, которые будут рассмотрены ниже), это предположение следует проверять

Регрессоры, коррелирующие с ошибкой, называются **эндогенными**

Свойства оценок МНК

- Обычные оценки метода наименьших квадратов в этом случае
 - смещены и
 - $p \lim_{n \to \infty} \widehat{\beta} = \beta + p \lim_{n \to \infty} \left[\left(\frac{X'X}{n} \right)^{-1} \frac{X'\mathcal{E}}{n} \right] = 0$

$$= \beta + \left(p \lim_{n \to \infty} \frac{1}{n} X'X \right)^{-1} \cdot p \lim_{n \to \infty} \frac{X'\mathcal{E}}{n} \neq \beta$$

- Содержательная интерпретация ошибочна
- Рекомендации, выработанные на основе модели неверны

Причины эндогенности

- 1. Пропуск существенных переменных
- 2. Ошибки измерения регрессоров
- 3. Самоотбор
- 4. Одновременность
- 5. Автокорреляция ошибок при наличии в уравнении лага зависимой переменной в роли регрессора
- Причины 2-5 по сути есть следствия причины 1
- Разные источники эндогенности могут иметь место одновременно
- Источники могут как усиливать, так и компенсировать друг друга

Пропуск существенной переменной (примеры)

Анализ рынка труда

- •Пропуск переменной «способности» при оценивании эффекта образования на заработную плату:
- •«способности» сильно и положительно коррелируют с образованием и, будучи пропущенными, приводят к смещению оценки эффекта образования вверх

Маркетинговые исследования

При анализе влияния **цен** или **рекламы** на **объемы продаж** пропускаются важные, но ненаблюдаемые характеристики локальных рынков или товаров:

- •уровень конкуренции,
- •слухи,
- •изменения во вкусах,
- •доли различных игроков,
- •наличие скидок,

Пропуск этих переменных, коррелированных с ценами и реакцией потребителя на рекламу, приводят к смещению оценок влияния последних

Пропуск существенной переменной

• Происходит, если оценивается модель (1) $Y = X\beta + \varepsilon$ а истинной является модель (2) $Y = X\beta + Z\gamma + \varepsilon$ Тогда оценка $\widehat{\beta}_{(1)}$ будет смещенной

$$E(\widehat{\beta}_{(1)}) = E[(X'X)^{-1}X'Y] = (X'X)^{-1}X'E(X\beta + Z\gamma + \varepsilon) =$$

$$= \beta + (X'X)^{-1}X'Z\gamma \neq \beta$$

Ошибки измерения регрессоров

Причины ошибок измерения

- Метод измерения
 - Ошибки метода измерения:
 - эффект ореола
 - эффекты интервьюирующего
 - искажения от эффекта социальной желательности (ошибки измерения переменных в обследованиях домохозяйств)
- Инструмент измерения
 - Неудачные шкалы рейтингов для измерения восприятия, вер, отношений, суждений
- Отсутствие физической единицы измерения
 - Ошибки измерения образования:
 - число лет обучения не отражает самообразования
- Ошибки агрегирования
 - Ошибки измерения цены в моделях совокупного спроса
 - потребители сталкиваются с разными ценами и товарными характеристиками

Самоотбор

Возникает, когда индивиды (фирмы) выбирают себе определенное состояние, руководствуясь скрытыми причинами:

- выходить на рынок труда или нет,
- быть или не быть членом бизнес-ассоциации,
- работать в бюджетном секторе или частном;
- или когда опрос ведется через интернет:

$$Y_i = \begin{cases} X_i' \beta + \varepsilon_i, & npo дажи в магазинах \\ X_i' (\beta + \delta) + \varepsilon_i, & npo дажи через интернет \end{cases}$$

$$Y_i = X_i' eta + D_i X_i' \delta + \mathcal{E}_i$$
 Тогда в модели $\exists \quad \mathrm{cov}ig(D_i, \mathcal{E}_iig)
eq 0$ возникает эндогенность, если

Одновременность

Проявляется, когда переменные правой части регрессионного уравнения определяются одновременно с зависимыми переменными, т.е. эндогенно порождаются процессом

- принятие решения об образовании или о выходе на рынок труда,
- формирование цены и величины спроса
- Кейнсианская модель потребления: $\exists \cos(Y_t, \varepsilon_t) \neq 0$

в модели $C_{t}=lpha+eta Y_{t}+arepsilon_{t}$ поскольку $Y_{t}=C_{t}+I_{t}$

Чтобы увидеть эту ковариацию, перепишем систему в приведенном

виде

$$\begin{cases} C_{t} = \frac{\alpha}{1-\beta} + \frac{\beta}{1-\beta} I_{t} + \frac{1}{1-\beta} \varepsilon_{t} \\ Y_{t} = \frac{\alpha}{1-\beta} + \frac{1}{1-\beta} I_{t} + \frac{1}{1-\beta} \varepsilon_{t} \end{cases}$$

$$\operatorname{cov}(Y_{t}, \varepsilon_{t}) = \operatorname{cov}\left(\frac{\alpha}{1-\beta} + \frac{1}{1-\beta}I_{t} + \frac{1}{1-\beta}\varepsilon_{t}, \varepsilon_{t}\right) = \frac{\sigma_{\varepsilon}^{2}}{1-\beta}$$

$$E(\widehat{\beta}) = E\left(\frac{\text{cov}(C,Y)}{V(Y)}\right) = E\left(\frac{\text{cov}(C,Y)}{V(Y)}\right) = \beta + \frac{\text{cov}(\varepsilon,Y)}{\sigma_y^2} = \beta + \frac{1}{1-\beta}\frac{\sigma_\varepsilon^2}{\sigma_y^2}$$

Авторегрессии с автокоррелированными ошибками

- Модель адаптивных ожиданий
- Эффект продажи каталога на вероятность покупки товара из каталога:
 - переменная почтовой рассылки и другие рекламные воздействия на потребителя функции прошлых продаж

$$Y_{t} = \alpha + \beta X_{t} + \gamma Y_{t-1} + \varepsilon_{t}, \quad \varepsilon_{t} = \rho \varepsilon_{t-1} + v_{t}$$

$$cov(Y_{t-1}, \varepsilon_{t}) = cov(\alpha + \beta X_{t-1} + \gamma Y_{t-2} + \varepsilon_{t-1}, \rho \varepsilon_{t-1} + v_{t}) =$$

$$= \rho \sigma_{\varepsilon}^{2} + \rho \gamma cov(Y_{t-2}, \varepsilon_{t-1}) = \frac{\rho \sigma_{\varepsilon}^{2}}{1 - \rho \gamma}$$

Методы оценивания

• Метод инструментальных переменных

$$\widehat{\beta}_{IV} = (Z'X)^{-1}Z'Y, V(\widehat{\beta}_{IV}) = \sigma_{\varepsilon}^{2}(Z'X)^{-1}Z'Z(Z'X)^{-1}$$

- инструментов Z столько же, сколько регрессоров, для экзогенных регрессоров инструменты они же сами
- $oldsymbol{eta}$ Двухшаговый МНК $\widehat{eta}_{TSLS} = (\widehat{X}'\widehat{X})^{-1}\widehat{X}'Y, \quad \widehat{X} = Z(Z'Z)^{-1}Z'X, \ V(\widehat{eta}_{TSLS}) = \sigma_{arepsilon}^2 ig(X'Z(Z'Z)^{-1}Z'Xig)^{-1}$
 - инструментов больше, чем регрессоров

Инструменты

Некие переменные Z, удовлетворяющие требованиям:

- сильная коррелированность с эндогенным регрессором Х
- некоррелированность с ошибкой $p \lim_{n \to \infty} \frac{Z'\varepsilon}{n} = 0$

ниу вшэ

Обобщенный метод моментов

- Стандартный метод инструментальных переменных это частный случай ОММ (обобщенного метода моментов)
- Если у нас имеется L инструментов, мы можем определить функцию

$$g_i(\beta) = Z_i \varepsilon_i = Z_i (Y_i - X_i'\beta)$$

которая называется моментом и представляет собой вектор размерности L, определенный для каждого наблюдения i=1,..., N

• Если инструменты экзогенны, то должны быть выполнены условия ортогональности или моментные тождества

$$E(g_i(\beta)) = 0$$

Обобщенный метод моментов

Выборочный аналог моментного тождества будет иметь вид:

$$\overline{g}(\beta) = \frac{1}{N} \sum_{i=1}^{N} g_i(\beta) = \frac{1}{N} \sum_{i=1}^{N} Z_i (Y_i - X_i'\beta) = \frac{1}{N} Z'\varepsilon$$

Оценка вектора коэффициентов будет решением уравнения (1) $\overline{g}(\beta) = 0$

- Если число моментных тождеств L (которое соответствует числу инструментов) совпадает с количеством регрессоров K, то решение уравнения (1) совпадает с \widehat{eta}_{IV}
- Если L>K, инструментов больше, чем регрессоров, то вместо уравнения (1)

в рамках ОММ решают задачу оптимизации квадратичной формы вида:

 $J(\beta) = N(\overline{g}(\beta))' W \overline{g}(\beta)$

где W – некая весовая матрица размера L*L

Оценка ОММ

• Из условия первого порядка: $\frac{\partial J(\beta)}{\partial \beta} = 0$ находят оценку:

$$\widehat{\beta}_{OMM} = (X'ZWZ'X)^{-1}X'ZWZ'Y$$

$$V(\widehat{\beta}_{OMM}) = \frac{1}{N} (X'ZWZ'X)^{-1} X'ZWSWZ'X (X'ZWZ'X)^{-1}$$

• В зависимости от выбора весовой матрицы W таких оценок можно построить множество, но есть оптимальная

$$W_{opt} = S^{-1}, S = \frac{1}{N} E(Z' \varepsilon \varepsilon' Z)$$

Свойства оценок ОММ

В общем случае, если ввести θ - вектор параметров, подлежащих оцениванию,

- ОММ оценка состоятельна: $\widehat{\theta}_{\scriptscriptstyle OMM} o heta$
- ОММ оценка асимптотически нормальна

$$\sqrt{N} (\widehat{\theta}_{OMM} - \theta) \rightarrow N(0, V)$$

• Асимптотическая ковариационная матрица оценки имеет вид: $V = \left(DW_{opt}D'\right)^{\!\!-1}$

где
$$D = E \left\{ \frac{\partial g(\theta)}{\partial \theta'} \right\}$$

Достоинства ОММ

- ОММ не требует предположений о распределении остатков
- OMM учитывает гетероскедастичность неизвестного вида, причем
 - $^{\circ}$ в отсутствии гетероскедастичности $\widehat{eta}_{\mathit{OMM}}$ асимптотически не хуже $\widehat{eta}_{\mathit{IV}}$
 - \circ при наличии гетероскедастичности eta_{OMM} эффективнее, чем $\widehat{eta}_{\mathit{IV}}$
- ОММ позволяет оценить параметры даже если их невозможно аналитически вывести из условия 1-го порядка
- При конструировании эмпирического аналога моментного тождества можно провести сглаживание с помощью ядерной функции. Это позволит уменьшить влияние нетипичных наблюдений, поскольку они будут учитываться с меньшими весами, нежели типичные наблюдения.

Тестирование качества инструментов

 Проверка коррелированности эндогенных регрессоров и инструментов (тестирование релевантности)

Если в модели $Y = X_1 \beta_1 + X_2 \beta_2 + \mathcal{E}$ X1 — эндогенны, Z — инструменты, то необходимо построить регрессии каждого столбца из X1 на Z и посмотреть на R2 или на F-статистику, которая должна быть >10, иначе Z — слабые инструменты

Тестирование качества инструментов

2. Проверка экзогенности инструментов (тестирование валидности)

Тест Хансена:

$$J(\widehat{\beta}_{\ni OMM}) = N(\overline{g}(\widehat{\beta}))' \widehat{S}^{-1} \overline{g}(\widehat{\beta}) \sim \chi_{L-K}^{2}$$

Его модификация при гетероскедастичности

$$J(\widehat{\beta}_{\ni OMM}) = \widehat{\varepsilon}' Z(Z'\widehat{\Omega}Z)^{-1} Z' \widehat{\varepsilon} \sim \chi_{L-K}^{2}$$

Его модификация при гомоскедастичности (тест Саргана)

$$J(\widehat{\beta}_{9OMM}) = \frac{1}{\widehat{\sigma}_{\varepsilon}^{2}} \widehat{\varepsilon}' Z(Z'Z)^{-1} Z' \widehat{\varepsilon} \sim \chi_{L-K}^{2}$$

Тестирование эндогенности регрессоров

- Тест Хаусмана
- Проверяется гипотеза Ho: $p \lim_{n \to \infty} \frac{X'\varepsilon}{n} = 0$
- на основании статистики

$$\eta = (\widehat{\beta}_{IV} - \widehat{\beta}_{MHK})' (V(\widehat{\beta}_{IV}) - V(\widehat{\beta}_{MHK}))^{-1} (\widehat{\beta}_{IV} - \widehat{\beta}_{MHK})^{H_0} \sim \chi_k^2$$

• которая сопоставляет две оценки,

 \widehat{eta}_{κ} - состоятельную и при Но, и при НА

 $\widehat{eta}_{M\!H\!K}$ - состоятельную и эффективную при Но, и несостоятельную при НА

Тестирование эндогенности регрессоров

Вместо теста Хаусмана можно проводить процедуру Дарбина-Ву:

пусть в модели
$$Y=X_1eta_1+eta_2X_2+\mathcal{E}$$

Х2 - единственный эндогенный регрессор, тогда процедура осуществляется в следующие три шага:

1. Строится вспомогательная регрессия

$$X_2 = X_1 \alpha_1 + \gamma Z + \nu \rightarrow \widehat{\nu}$$

Теперь необходимо выяснить, будет ли Х2 ортогонален ε, но это то же самое, что выяснение ортогональности ν и ε

2. Для этого строится регрессия

$$Y = X_1 \beta_1 + \beta_2 X_2 + \delta \hat{v} + \varepsilon$$

3. Проверяется значимость влияния $\widehat{\mathcal{V}}$

Проблема выбора инструментов

- Инструменты должны браться вне модели
- Требования к инструментам противоречивы:
 - Если Z должны сильно коррелировать с X, а X должны сильно коррелировать с У, то Z будут сильно коррелировать с У, а, следовательно, коррелировать с ошибкой
- Следствия противоречивости требований к инструментам
 - Либо инструменты экзогенные (нет корреляции с ошибкой), но слабые (слабо коррелируют с X)
 - Либо инструменты сильные (сильно коррелируют с X), но эндогенные (сильно коррелируют с ошибкой)

Выбор числа инструментов

- Лучше не более трех-четырех (для одного эндогенного регрессора)
- Можно использовать метод главных компонент для инструментов и выбирать компоненты, наиболее связанные с X, отбрасывая остальные
- Чем слабее инструменты, тем меньше их должно быть

Источники инструментов

- Если есть панель, то часто инструменты не нужны
- Инструментом может быть переменная группировки (группировка должна различать ненаблюдаемые высокие и низкие значения пропущенной переменной)
- Инструментом может быть лаг высокого порядка
- Можно использовать легкодоступные экзогенные переменные, не включенные в модель

Спасибо за внимание!