


Анализ временных рядов и прогнозирование

Динамические регрессионные модели






Анализ временных рядов и прогнозирование

Определение

- Временной ряд (ВР) – это последовательность значений, описывающих протекающий во времени процесс, измеренных в последовательные моменты времени, обычно через равные промежутки.
- Данные типа временных рядов широко распространены в самых разных областях человеческой деятельности. В экономике это ежедневные цены на акции, курсы валют, еженедельные и месячные объемы продаж, годовые объемы производства и т.п.

Графики временных рядов



- на 1-ом графике виден явный линейный тренд,
- на 2-ом – случайные колебания с кластерами волатильности
- на 3-ем – сложный цикл

В рамках нашего курса мы рассмотрим:

- методы подбора математической модели для описания ВР;
- методы выявления периодической и других составляющих ВР;
- прогнозирование поведения ВР ;
- способы изучения взаимозависимостей ВР

При анализе ВР принято выделять 4 компоненты

- тренд (Т)
- циклическая компонента (С)
- сезонная компонента (S)
- случайная компонента (e) –
остается после полного
вычленения закономерных
компонент.

Тренд

- тренд (Т) – плавно изменяющаяся компонента, описывающая чистое влияние долговременных факторов (рост население, изменение структуры возрастного состава и т.д.)

Циклическая компонента

- циклическая компонента (С) – плавно изменяющаяся компонента, описывающая длительные периоды относительного подъема и спада,
- состоит из циклов, меняющихся по амплитуде и протяженности
- в экономике бывает связана со взаимодействием спроса и предложения, ростом и истощением ресурсов, изменением в финансовой и налоговой политике и т.п.

Сезонная компонента

- сезонная компонента (S) – состоит из последовательности почти повторяющихся циклов
- объем продаж накануне Нового Года, объем перевозок пассажиров городским транспортом

Случайная компонента

- случайная компонента (e) – остается после полного вычленения закономерных компонент
- иногда содержит часть, поддающуюся моделированию и прогнозированию

ВР представляется

- либо суммой этих компонент

$$Y = T + C + S + e$$

в аддитивной модели,

- либо произведением

$$Y = T * C * S * e$$

в мультипликативной модели.

Второй вариант более распространен в экономических приложениях и сводится к первому логарифмированием

Трендовая составляющая выделяется методом наименьших квадратов

Наиболее распространены следующие модели трендов:

- линейная - $T_t = \beta_0 + \beta_1 t$
- полиномиальная - $T_t = \beta_0 + \beta_1 t + \beta_2 t^2 + \dots + \beta_k t^k$
- экспоненциальная - $T_t = \exp(\beta_0 + \beta_1 t)$

Представление о характере тренда можно получить из графика ВР

Учет сезонности

- В аддитивной модели учесть сезонность можно с помощью фиктивных переменных
- Например, уравнение для учета тренда и квартальной сезонности может быть таким:

$$Y_t = \beta_0 + \beta_1 t + \alpha_1 D_{1t} + \alpha_2 D_{2t} + \alpha_3 D_{3t} + \varepsilon_t$$

Построение прогноза для ВР

- Прогнозирование в бизнесе играет очень большую роль, поскольку является рациональной основой для принятия решений.
- Например, предсказание ежемесячных объемов продаж товара – это основа политики контролирования запасов, предсказание будущих доходов корпорации – основа для принятия решений в инвестиционной политике.
- Задача прогнозирования состоит в том, чтобы по имеющимся наблюдениям ВР предсказать его неизвестные будущие значения

Подход Бокса-Дженкинса ARIMA

Методы ARIMA предназначены для моделирования и прогнозирования

- либо стационарных ВР,
- либо ВР, которые могут быть преобразованы к стационарным

Понятие стационарности ВР

- Например, если ВР Y содержит линейный тренд и квартальную сезонность,
- то остатки регрессионной модели

$$Y_t = \beta_0 + \beta_1 t + \alpha_1 D_{1t} + \alpha_2 D_{2t} + \alpha_3 D_{3t} + \varepsilon_t$$

будут стационарным ВР

Понятие стационарности ВР

- Ряд является *стационарным, если он совершает колебания вокруг своего математического ожидания, которое является константой.*
- Амплитуда колебаний при этом примерно постоянна.
- Сами значения ряда не являются, как правило, независимыми, *но корреляция между членами ряда ε_t и ε_{t-s} зависит только от расстояния s между ними.*

Понятие строгой стационарности

- Ряд ε_t называется строго стационарным или стационарным в узком смысле, если совместное распределение

$$F(\varepsilon_1, \varepsilon_2, \dots, \varepsilon_T)$$

не зависит от сдвига по времени,

т.е. совпадает с распределением

$$F(\varepsilon_{1+s}, \varepsilon_{2+s}, \dots, \varepsilon_{T+s})$$

для любых T и s

Понятие слабой стационарности

- Ряд ε_t называется слабо стационарным или стационарным в широком смысле, если

$$E(\varepsilon_t) = \mu = \text{const}$$

$$V(\varepsilon_t) = \sigma^2 = \text{const}$$

$$\text{cov}(\varepsilon_t, \varepsilon_{t-s}) = \rho(s)$$

- Если нарушается хотя бы одно из этих условий, то ряд называется нестационарным
- Строгая стационарность подразумевает слабую стационарность

TS ряды

- Временной ряд Y_t называется стационарным относительно детерминированного тренда $f(t)$, если ряд $Y_t - f(t)$ стационарный.
- Тогда говорят, что этот ряд является TS рядом (TS –trend stationary).

Подход Бокса-Дженкинса ARIMA

- Предположение о том, что существует связь между соседними значениями ВР и составляет основу методов ARIMA
- Именно эта гипотеза позволяет предсказать значения $\varepsilon_{t+1}, \varepsilon_{t+2}, \dots$ на основании известных значений $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_t$
- затем по регрессионной модели
$$Y_t = \beta_0 + \beta_1 t + \alpha_1 D_{1t} + \alpha_2 D_{2t} + \alpha_3 D_{3t} + \varepsilon_t$$
- строятся будущие значения Y_{t+1}, Y_{t+2}, \dots

ARIMA(p,d,q), подбор параметра d

- Ряд ε_t считается реализацией случайного процесса $ARIMA(p,d,q)$, и в зависимости от типа этого процесса строится прогноз.
- Параметр d называется порядком интегрированности ряда
- Если исходный ряд стационарен, то $d=0$
- Тогда $\varepsilon_t \sim ARIMA(p,0,q) = ARMA(p,q)$
- На следующем шаге подбираются параметры p и q для процессов AR и MA.

ARIMA(p,d,q), подбор параметра d

- Если исходный ряд не является стационарным, то иногда его можно преобразовать к стационарному виду
- Тогда возможны 2 случая:

- ряд стационарен в первых разностях

$$\Delta \varepsilon_t = \varepsilon_t - \varepsilon_{t-1} \sim ARMA(p, q)$$

тогда $d=1$ и $\varepsilon_t \sim ARIMA(p, 1, q)$

- ряд стационарен во вторых разностях

$$\Delta^2 \varepsilon_t = \Delta \varepsilon_t - \Delta \varepsilon_{t-1} = \varepsilon_t - 2\varepsilon_{t-1} + \varepsilon_{t-2} \sim ARMA(p, q)$$

тогда $d=2$ и $\varepsilon_t \sim ARIMA(p, 2, q)$

ARIMA(p,d,q), подбор параметра d

- Ряд $\varepsilon_t \sim ARIMA(p, 1, q)$ называется интегрированным 1-го порядка $I(1)$
- Ряд $\varepsilon_t \sim ARIMA(p, 2, q)$ называется интегрированным 2-го порядка $I(2)$
- Ряды класса TS не относят к интегрированным
- $\varepsilon_t \sim I(0)$ соответствует стационарному ряду, который не является результатом дифференцирования TS ряда

Прогноз процесса AR(p)

Если $\varepsilon_t \sim \text{AR}(p)$, то

$$\varepsilon_t = a_0 + a_1 \varepsilon_{t-1} + \dots + a_p \varepsilon_{t-p} + u_t$$

$$u_t \sim N(0, \sigma^2)$$

Тогда прогнозное значение

$$\widehat{\varepsilon}_{t+1} = \widehat{a}_0 + \widehat{a}_1 \varepsilon_t + \dots + \widehat{a}_p \varepsilon_{t-p+1}$$

Прогноз процесса МА(q)

Если $\varepsilon_t \sim \text{МА}(q)$, то

$$\varepsilon_t = a_0 + b_1 u_{t-1} + \dots + b_q u_{t-q} + u_t$$

$$u_t \sim N(0, \sigma^2)$$

и прогноз

$$\widehat{\varepsilon}_{t+1} = \widehat{a}_0 + \widehat{b}_1 u_t + \dots + \widehat{b}_q u_{t-q+1}$$

Прогноз процесса ARMA(1,1)

- Если $\varepsilon_t \sim \text{ARMA}(1,1)$, то

$$\varepsilon_t = a_0 + a_1 \varepsilon_{t-1} + b_1 u_{t-1} + u_t$$

$$u_t \sim N(0, \sigma^2)$$

- и прогнозное значение

$$\widehat{\varepsilon}_{t+1} = \widehat{a}_0 + \widehat{a}_1 \varepsilon_t + \widehat{b}_1 u_t$$

Алгоритм подбора модели ВР

1. Тестирование на стационарность (тест Unit Root).
Если результат положительный, то пункт 3.
2. Приведение к стационарному виду взятием 1-ой или 2-ой разности и снова пункт 1.
3. Идентификация параметров p и q процесса $ARMA(p,q)$ по коррелограммам АС и РАС.
4. Оценивание параметров методом максимального правдоподобия и выбор наилучшей модели (**критерии Акаике, Шварца**).
5. Диагностическая проверка (анализ коррелограмм АС и РАС).



Тестирование стационарности

Тестирование стационарности ВР (тест Дики-Фуллера)

- Для одной из моделей (какой именно, можно выбрать, используя опции)

$$\varepsilon_t = \rho \varepsilon_{t-1} + u_{1t}$$

$$\varepsilon_t = \alpha + \rho \varepsilon_{t-1} + u_{2t}$$

$$\varepsilon_t = \alpha + \rho \varepsilon_{t-1} + ct + u_{3t}$$

- Оценивается уравнение $\Delta \varepsilon_t = \gamma \varepsilon_{t-1} + u_t, \quad \gamma = \rho - 1$
- Проверяется гипотеза $H_0 : \gamma = 0$
- Если она не отвергается, это говорит о наличии единичного корня $\rho = 1$, т.е. о нестационарности ВР
- В этом случае $\varepsilon_t = \varepsilon_{t-1} + u_t$ и $\widehat{\varepsilon}_{t+1} = \varepsilon_t$

Тестирование стационарности ВР (тест Дики-Фуллера с константой и трендом)

```
dfuller je, trend regress lags(0)
```

Dickey-Fuller test for unit root Number of obs = 139

----- Interpolated Dickey-Fuller -----				
Test		1% Critical	5% Critical	10% Critical
Statistic		Value	Value	Value

Z(t)	-1.040	-4.027	-3.445	-3.145

MacKinnon approximate p-value for Z(t) = 0.9384

-----+-----							
D.je		Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
-----+-----							
je							
L1.		-.0053434	.0051367	-1.04	0.300	-.0155015	.0048147
_trend		.0001407	.000036	3.90	0.000	.0000694	.000212
_cons		-.0011287	.0011835	-0.95	0.342	-.003469	.0012117

- Тестовая статистика $Z(t) = -1.04$, это значение не попадает в критическую область при любом разумном уровне значимости, гипотеза о наличии единичного корня не отвергается, исследуемый ряд нестационарен

Тестирование стационарности ВР (тест Дики-Фуллера)

- Статистика теста (DF-статистика) — это обычная t -статистика для проверки значимости коэффициентов линейной регрессии. Однако, распределение данной статистики отличается от классического распределения.
- Распределение DF-статистики выражается через винеровский процесс и называется распределением Дики — Фуллера.

Тест Дики-Фуллера

- Для каждой из трёх тестовых регрессий существуют свои критические значения DF -статистики, которые берутся из специальной таблицы Дики — Фуллера (МакКиннона).
- Если значение статистики лежит левее критического значения (критические значения — отрицательные) при данном уровне значимости, то нулевая гипотеза о единичном корне отклоняется и процесс признается стационарным (в смысле данного теста). В противном случае гипотеза не отвергается и процесс может содержать единичные корни, то есть быть нестационарным (интегрированным) временным рядом.

Тестирование стационарности ВР (тест Дики-Фуллера)

Критические значения статистики Дики — Фуллера при 1%-ном уровне значимости. Для сравнения: критическое значение распределения Стьюдента для всех моделей на больших объёмах выборки — 2,33, на малых выборках — 2,5. МакКинноном выведены приблизительные формулы для оценки критических значений.

Размер выборки	AR-модель	AR-модель с константой	AR-модель с константой и трендом
25	-2,66	-3,75	-4,38
50	-2,62	-3,58	-4,15
100	-2,60	-3,51	-4,04
∞	-2,58	-3,43	-3,96

Теоретически обоснованным является тестирование в первую очередь вторых разностей ряда. Если гипотеза единичного корня для этого ряда отвергается, то тогда тестируется единичный корень в первых разностях. Если на этом этапе гипотеза не отвергается, то исходный ряд имеет два единичных корня. Если отвергается, то проверяется единичный корень в самом временном ряде.

Проблемы теста DF

- Низкая мощность: часто не отвергается исходная (нулевая) гипотеза, когда она в действительности не выполняется
- Невыполнение теоретических предпосылок для вспомогательных моделей в тестах: смещена статистика теста.
- Может даже отвергаться нулевая гипотеза, когда в действительности она верна
- Рассмотренный DF тест рекомендовано использовать при условии гомоскедастичности и некоррелированности случайных отклонений тестируемой модели

Альтернативные тесты

- Расширенный тест DF- ADF для учета автокорреляции

$$\Delta \varepsilon_t = \gamma \varepsilon_{t-1} + \sum_{k=1}^K \alpha_k \Delta \varepsilon_{t-k} + u_{1t}$$

$$\Delta \varepsilon_t = \alpha + \gamma \varepsilon_{t-1} + \sum_{k=1}^K \alpha_k \Delta \varepsilon_{t-k} + u_{2t}$$

$$\Delta \varepsilon_t = \alpha + \gamma \varepsilon_{t-1} + ct + \sum_{k=1}^K \alpha_k \Delta \varepsilon_{t-k} + u_{3t}$$

- самое простое правило подбора K - включать 2 лага при объеме выборки меньше 81 наблюдения, 3 лага при объеме выборки от 81 до 256 наблюдений и т.д. [Канторович]

Альтернативные тесты

- РР-тест (тест Филлипса-Перрона):
Используется при нарушении гипотезы о некоррелированности, гомоскедастичности и нормальности отклонений в тестируемой модели.
- РР-тест рекомендуется также к использованию в случаях наличия ярко выраженной сезонности и структурных сдвигов (скачков).

Подбор параметров модели ARMA

Идентификация параметров ARMA(p,q)

Автокорреляционная функция

Пусть X – некоторый временной ряд,
тогда его теоретическая АКФ (АС) имеет вид:

$$\rho(\tau) = \frac{1}{\text{Var}(X_t)} E\{(X_t - \mu)(X_{t-\tau} - \mu)\}$$




Рис. 1. Значения автокорреляционной функции процесса AR(1) при значении коэффициента равном 0,8




Рис. 2. Значения автокорреляционной функции процесса AR(1) при значении коэффициента равном -0,8

Идентификация параметров ARMA(p,q)



Частная автокорреляционная функция

Частная АКФ (РАС) определяется из системы линейных уравнений Юла-Уокера, связывающей значения АКФ и частной АКФ

$$\begin{cases} \rho_1 = \varphi_{k1} \cdot 1 + \varphi_{k2} \rho_1 + \varphi_{k3} \rho_2 + \dots + \varphi_{kk} \rho_{k-1} \\ \rho_2 = \varphi_{k1} \rho_1 + \varphi_{k2} \cdot 1 + \varphi_{k3} \rho_1 + \dots + \varphi_{kk} \rho_{k-2} \\ \dots \\ \rho_k = \varphi_{k1} \rho_{k-1} + \varphi_{k2} \rho_{k-2} + \varphi_{k3} \cdot \rho_{k-3} + \dots + \varphi_{kk} \cdot 1. \end{cases}$$

Идентификация параметров ARMA



Вид коррелограмм АС и РАС для $\rho > 0$

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob	
		1	0.539	0.539	116.40	0.000
		2	0.319	0.041	157.37	0.000
		3	0.190	0.004	171.91	0.000
		4	0.092	-0.029	175.35	0.000
		5	0.014	-0.044	175.43	0.000
		6	0.012	0.033	175.50	0.000
		7	-0.013	-0.026	175.56	0.000
		8	0.025	0.059	175.81	0.000
		9	0.042	0.018	176.52	0.000
		10	0.069	0.042	178.47	0.000
		11	0.027	-0.051	178.78	0.000
		12	0.036	0.028	179.32	0.000

$$\text{AR}(1). \quad Y_t = 0.5Y_{t-1} + \varepsilon_t$$


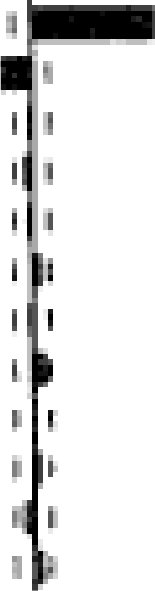
Идентификация параметров ARMA

Вид коррелограмм АС и РАС для $\rho > 0$

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob
		1 -0.500	-0.500	100.19	0.000
		2 0.281	0.041	131.88	0.000
		3 -0.125	0.041	138.15	0.000
		4 0.104	0.063	142.49	0.000
		5 -0.106	-0.049	147.01	0.000
		6 0.090	0.009	150.33	0.000
		7 -0.096	-0.043	154.11	0.000
		8 0.080	0.011	156.70	0.000
		9 -0.068	-0.010	158.57	0.000
		10 0.103	0.074	162.91	0.000
		11 -0.081	0.009	165.60	0.000
		12 0.063	-0.002	167.23	0.000

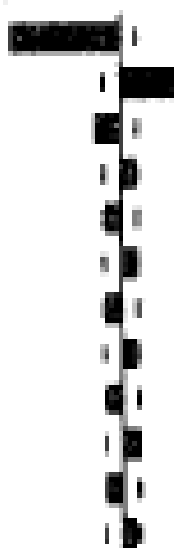
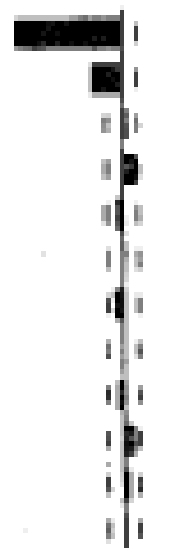
$$\text{AR}(1). \quad Y_t = -0.5Y_{t-1} + \epsilon_t$$

Идентификация параметров ARMA

Autocorrelation	Partial Correlation		AC	PAC	Q-Stat	Prob
		1	0.700	0.700	196.54	0.000
		2	0.403	-0.171	261.80	0.000
		3	0.203	-0.016	278.34	0.000
		4	0.072	-0.037	280.46	0.000
		5	-0.006	-0.023	280.47	0.000
		6	-0.021	0.035	280.64	0.000
		7	-0.022	-0.016	280.84	0.000
		8	0.017	0.071	280.95	0.000
		9	0.049	0.008	281.93	0.000
		10	0.071	0.025	283.99	0.000
		11	0.051	-0.043	285.05	0.000
		12	0.048	0.045	286.00	0.000


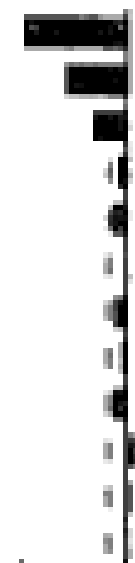
AR(2). $Y_t = 0.8Y_{t-1} - 0.2Y_{t-2} + \epsilon_t$

Идентификация параметров ARMA

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob	
		1	-0.670	-0.670	179.75	0.000
		2	0.353	-0.173	229.82	0.000
		3	-0.147	0.028	238.48	0.000
		4	0.087	0.083	241.55	0.000
		5	-0.088	-0.032	244.67	0.000
		6	0.080	0.009	247.99	0.000
		7	-0.087	-0.042	251.78	0.000
		8	0.088	0.007	254.98	0.000
		9	-0.086	-0.030	257.98	0.000
		10	0.106	0.062	262.57	0.000
		11	-0.092	0.029	266.04	0.000
		12	0.071	0.010	268.12	0.000


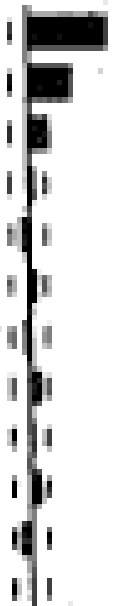
AR(2). $Y_t = -0.8Y_{t-1} - 0.2Y_{t-2} + \epsilon_t$

Идентификация параметров ARMA


Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob	
		1	-0.593	-0.593	140.88	0.000
		2	0.124	-0.351	147.01	0.000
		3	0.004	-0.185	147.02	0.000
		4	0.026	-0.034	147.29	0.000
		5	-0.069	-0.068	149.21	0.000
		6	0.076	0.003	151.55	0.000
		7	-0.074	-0.050	153.79	0.000
		8	0.056	-0.014	155.06	0.000
		9	-0.055	-0.058	156.32	0.000
		10	0.088	0.050	159.47	0.000
		11	-0.077	0.024	161.89	0.000
		12	0.035	0.010	162.40	0.000

MA(2). $Y_t = \epsilon_t - 0.9\epsilon_{t-1} + 0.2\epsilon_{t-2}$.

Идентификация параметров ARMA

Autocorrelation	Partial Correlation		AC	PAC	Q-Stat	Prob
		1	0.449	0.449	80.885	0.000
		2	0.389	0.234	141.60	0.000
		3	0.320	0.108	182.89	0.000
		4	0.246	0.025	207.30	0.000
		5	0.162	-0.037	217.92	0.000
		6	0.161	0.040	228.44	0.000
		7	0.100	-0.021	232.54	0.000
		8	0.121	0.053	238.50	0.000
		9	0.102	0.019	242.73	0.000
		10	0.123	0.052	248.91	0.000
		11	0.057	-0.053	250.23	0.000
		12	0.067	0.002	252.10	0.000

ARMA(1,1). $Y_t = 0.8Y_{t-1} + \varepsilon_t - 0.5\varepsilon_{t-1}$



Метод максимального правдоподобия ММП

Метод максимального правдоподобия для КЛРМ

- Рассмотрим, как этот метод работает для классической регрессионной модели

$$Y_i = X_i' \beta + \varepsilon_i \quad \varepsilon \sim N(0, \sigma_\varepsilon^2 I)$$

- Функция плотности Y_i
при данных X_i имеет вид:

$$f(Y_i | \beta, \sigma_\varepsilon^2) = \frac{1}{\sqrt{2\pi\sigma_\varepsilon^2}} \exp \left\{ -\frac{1}{2} \frac{(Y_i - X_i' \beta)^2}{\sigma_\varepsilon^2} \right\}$$

Оценка ММП для классической линейной регрессии

- Соответствующая логарифмическая функция правдоподобия будет иметь вид:

$$\begin{aligned}\ln L(\beta, \sigma_\varepsilon^2) &= \sum_{i=1}^n \ln L_i(\beta, \sigma_\varepsilon^2) = \sum_{i=1}^n \ln f(Y_i | \beta, \sigma_\varepsilon^2) = \\ &= -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma_\varepsilon^2 - \frac{1}{2\sigma_\varepsilon^2} \sum_{i=1}^n (Y_i - X_i' \beta)^2\end{aligned}$$

- Далее находятся оценки параметров, обеспечивающие максимум этой функции

Оценка ММП для классической линейной регрессии

- Условия первого порядка

$$\frac{\partial \ln L(\beta, \sigma_{\varepsilon}^2)}{\partial \beta} = 0 \quad \frac{\partial \ln L(\beta, \sigma_{\varepsilon}^2)}{\partial \sigma_{\varepsilon}^2} = 0$$

- приводят к уравнениям

$$\frac{1}{\sigma_{\varepsilon}^2} \frac{\partial}{\partial \beta} \sum_{i=1}^n X_i (Y_i - X_i' \beta) = 0$$

$$-\frac{n}{2\sigma_{\varepsilon}^2} + \frac{1}{2\sigma_{\varepsilon}^4} \sum_{i=1}^n (Y_i - X_i' \beta)^2 = 0$$

Оценка ММП моделей ARMA

Пусть y_t подчиняется процессу ARMA(1,1)
Введем обозначения:

$$y_1^* = y_1, \quad y_2^* = y_2 + \theta_1 y_1, \quad \dots \quad y_t^* = y_t + \theta_1 y_{t-1} + \dots + \theta_1^{t-1} y_1.$$

И будем оценивать модель вида

$$y_t^* = \delta^* + \phi_1 y_{t-1}^* + \varepsilon_t$$

$$\varepsilon_t \sim iid N(0, \sigma^2)$$

Оценка ММП моделей ARMA

Логарифм функции правдоподобия для ARMA(1,1) будет иметь вид:

$$\begin{aligned} l(\delta, \phi_1, \theta_1, \sigma^2) = \\ = \text{const} - \frac{n}{2} \ln \sigma^2 + \frac{1}{2} \ln(1 - \phi_1^2) - \frac{1 - \phi_1^2}{2\sigma^2} \left(y_1^* - \frac{\delta^*}{1 - \phi_1} \right)^2 \\ - \frac{1}{2\sigma^2} \sum_{t=2}^n (y_t^* - \delta^* - \phi_1 y_{t-1}^*)^2. \end{aligned}$$

Критерии качества подгонки

Информационный критерий Акаике (AIC)

$$AIC = -2 \frac{l}{T} + 2 \frac{k}{T}$$

Информационный критерий Шварца (BIC)


$$BIC = SC = -2 \frac{l}{T} + \frac{k \log T}{T}$$

l – логарифм функции правдоподобия,

k – число оцениваемых параметров.

Чем ниже значения критериев, тем лучше
результат

ARIMA (1,0,1) regression



Sample: 1 - 66

Log likelihood = 81.4261

Number of obs = 66
Wald chi2(2) = 215.46
Prob > chi2 = 0.0000

sp500	Coef.	Std. Err.	z	P>z	[95% Conf.Interval]
_cons	7.135755	.1141207	62.53	0.000	6.912083 7.359427


ARMA

L1.ar	.9018984	.0822384	10.97	0.000	.7407141	1.063083
L1.ma	.3435668	.1170013	2.94	0.003	.1142484	.5728852
/sigma	.0692228	.0065627	10.55	0.000	.05636	.0820855

GARCH модели BP

Из эмпирических наблюдений над поведением BP процентных ставок, валютных курсов и т.п. было замечено, что наблюдения с большими отклонениями от среднего и с малыми отклонениями склонны к образованию кластеров

Однодневные приращения индекса РТС



GARCH модели BP

- Это явление оказалось удобно моделировать зависимостью дисперсии ошибок от предыстории

$$\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \dots + \alpha_p u_{t-p}^2.$$

- Простейшая модель этого класса ARCH(1) запишется в виде:

$$y_t = x_t' \beta + u_t.$$

$$u_t = \epsilon_t (\alpha_0 + \alpha_1 u_{t-1}^2)^{1/2}, \quad \epsilon_t \sim iid N(0, 1).$$

GARCH модели ВР

- Если сформулировать зависимость дисперсии от предыстории в более общем виде

$$\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \cdots + \alpha_p u_{t-p}^2 + \gamma_1 \sigma_{t-1}^2 + \cdots + \gamma_q \sigma_{t-q}^2$$

- то это приведет к моделям GARCH(p,q).
- Простейшую модель этого вида GARCH(1,1) можно записать так:

$$y_t = x_t' \beta + u_t$$

$$u_t = \varepsilon_t \left(\alpha_0 + \alpha_1 u_{t-1}^2 + \gamma_1 \sigma_{t-1}^2 \right)^{1/2},$$

$$\varepsilon_t \sim iidN(0,1)$$

ARCH family regression

- Sample: 1 - 66
- Distribution: Gaussian
- Log likelihood = 33.74703
- Number of obs = 66
- Wald chi2(.) = .
- Prob > chi2 = .
- -----
- sp500 | Coef. Std. Err. z P>|z| [95% Conf. Interval]
- -----+-----
- _cons | 7.071681 .0140875 501.98 0.000 7.04407 7.099292
- -----+-----
- ARCH
- L1. arch | 1.004295 .6102791 1.65 0.100 -.1918305 2.20042
- L1. garch | -.0887646 .2598499 -0.34 0.733 -.5980609 .4205318
- _cons | .0053252 .0055901 0.95 0.341 -.0056312 .0162816
- -----

Метод оценивания моделей GARCH

- Модели GARCH оцениваются методом максимального квазиправдоподобия, что означает следующее:
 - используется гипотеза о нормальности, даже если ошибка ненормальна,
 - делается специальная корректировка при вычислении стандартных ошибок

Условия состоятельности оценок

- 1. Условие верной идентификации первых моментов

$$E(\varepsilon_t | z_{t-1}) = 0, \quad E(\varepsilon_t^2 | z_{t-1}) = 1$$

- 2. Условие стационарности

$$E\{\ln(\alpha_1 \varepsilon_t^2) | z_{t-1}\} < 0 \quad \alpha_1 > 0$$

- 3. Условие асимптотической нормальности


$$E(\varepsilon_t^4 | z_{t-1}) - \text{ограничено}$$

Достоинства моделей GARCH

- Метод позволяет оценивать регрессии

$$y_t = x_t' \beta + u_t$$

- с не гауссовскими (не нормальными) распределениями ошибок при наличии тяжелых хвостов,
- успешно справляется с сериальной корреляцией квадратов ошибок
- несложно приспособиваются для моделирования финансовых ВР



Динамические регрессионные модели

Построение зависимостей между различными ВР

- Для ВР появляется возможность строить более сложные и реалистичные модели явлений, учитывающие запаздывание реакции зависимой переменной на изменения независимых переменных, а также память в самой зависимой переменной например:

$$Y_t = a_0 + b_0 X_t + b_1 X_{t-1} + \gamma Y_{t-1} + \varepsilon_t$$

Построение зависимостей между различными ВР

- Если ряды X_t и Y_t не являются стационарными, зависимость между ними может оказаться ложной.
- Надо обязательно выделять тренд и сезонность.
- Признаками ложной регрессии являются высокий R^2 при низкой статистике Дарбина-Уотсона DW.

Например

$$y_t = -\frac{2.79}{(-5.77)} - \frac{0.52}{(-21.5)} x_t; \quad R^2 = 0.607, \quad DW = 0.057$$

Тест Дарбина-Уотсона

- **Тест Дарбина-Уотсона** используется для проверки гипотезы об отсутствии автокорреляции первого порядка в остатках регрессионной модели.
- Пусть (e_1, \dots, e_n) - это вектор остатков линейной регрессии по k независимым переменным.
- Предполагая, что остатки образуют процесс $AR(1)$
$$e_t = \rho e_{t-1} + u_t$$
где u_t – последовательность независимых нормальных случайных величин.

Тест Дарбина-Уотсона

- Тест основан на проверке гипотезы об отсутствии автокорреляции

$$H_0: \rho = 0,$$

- критерием служит статистика Дарбина-Уотсона, которая рассчитывается по следующей формуле:

$$DW = \sum_{t=2} (e_t - e_{t-1})^2 / \sum_{t=2} e_t^2$$

$$DW \approx 2(1 - \rho)$$

Тест Дарбина-Уотсона

- Поскольку $DW \approx 2(1 - \rho)$, где ρ - коэффициент корреляции между e_i и e_{i-1} , значения DW находятся в промежутке от 0 до 4.
- При $\rho = 0$ DW близка к 2.
- Близость DW к нулю говорит о положительной автокорреляции, к 4 - об отрицательной.
- На практике проверка гипотезы H_0 об отсутствии автокорреляции остатков осуществляется с помощью сравнения статистики DW с теоретическими значениями d_l и d_u для заданного числа наблюдений n , числа независимых переменных модели k и уровня значимости α

Тест Дарбина-Уотсона

- $0 < DW < d_l$ - гипотеза H_0 отвергается, есть положительная автокорреляция;
- $d_l < DW < d_u$ - зона неопределённости;
- $d_u < DW < 4 - d_u$ - гипотеза H_0 не отвергается, автокорреляции нет;
- $4 - d_u < DW < 4 - d_l$ - зона неопределённости;
- $4 - d_l < DW < 4$ - гипотеза H_0 отвергается, есть отрицательная автокорреляция.

Проблемы моделирования зависимостей между ВР

- Временные ряды X_t и Y_t – имеют различный тип нестационарности.
- Например, ряд Y_t является нестационарным и интегрированным порядка k , а X_t является TS-рядом.
- В таких случаях может иметь место ложная регрессионная зависимость, а операции исключения тренда или перехода к разностям не гарантируют принадлежности случайных отклонений классу «гауссов белый шум»

Проблемы моделирования зависимостей между ВР

- Временные ряды X_t и Y_t имеют различный порядок интегрирования, т.е. $X_t \sim I(k)$, $Y_t \sim I(l)$, $k \neq l$
- при этом ряд остатков модели содержит стохастический тренд.
- В таком случае может иметь место ложная регрессионная зависимость
- Целесообразно строить модель на основе временных рядов разностей соответствующих порядков

Коинтеграция ВР

- Не ложная регрессия между нестационарными ВР возможна, если ВР являются коинтегрированными.
- Это означает либо стационарность ошибки для некоторой линейной комбинации

$$\alpha y_t + x_t' \beta = u_t$$

- Либо в более общем случае, линейная комбинация рядов с порядком интегрирования d имеет более низкий порядок интегрирования $d-1$

Построение зависимостей между различными ВР

- Серьезной проблемой регрессионных зависимостей для ВР является автокорреляция ошибок.
- Иногда выбор удачной динамической спецификации, формы тренда или учет сезонности позволяют ее избежать.
- Отдельный сложный вопрос – направление причинно-следственной связи.

Причинность по Грэнджеру

- Способ выяснить статистическую причинность предлагает тест Грэнджера
- Оцениваются две регрессии:

$$y_t = \alpha_0 + \alpha_1 y_{t-1} + \dots + \alpha_p y_{t-p} + \beta_1 x_{t-1} + \dots + \beta_p x_{t-p} + \varepsilon_t$$

$$x_t = \alpha_0 + \alpha_1 x_{t-1} + \dots + \alpha_p x_{t-p} + \beta_1 y_{t-1} + \dots + \beta_p y_{t-p} + u_t$$

- И для каждой проверяется гипотеза

$$\beta_1 = \dots = \beta_p = 0$$

Популярные спецификации регрессионных моделей для ВР

- Модель частичного приспособления
- Модель адаптивных ожиданий
- Модель коррекции ошибок
- Модель векторной авторегрессии (VAR)

Модель частичного приспособления

Пример. Рассмотрим зависимость между оптимальным (ненаблюдаемым) потреблением бензина и ценами на нефть:

$$Y_t^* = a + bX_t + \varepsilon_t$$

Реальное потребление постепенно приближается к оптимальному по правилу

$$Y_t - Y_{t-1} = (1 - \lambda)(Y_t^* - Y_{t-1})$$

Итоговая модель

$$Y_t = (1 - \lambda)\alpha + (1 - \lambda)\beta X_t + \lambda Y_{t-1} + u_t, u \sim N(0, \sigma^2 I)$$

Модель адаптивных ожиданий

Пример. Рассмотрим зависимость между выпуском и оптимальным (ненаблюдаемым) объемом продаж

$$Y_t = a + bX_t^* + \varepsilon_t$$

Реальные продажи постепенно приближаются к оптимальным по правилу

$$X_t^* - X_{t-1}^* = (1 - \lambda)(X_{t-1} - X_{t-1}^*)$$

Итоговая модель

$$Y_t = (1 - \lambda)\alpha + (1 - \lambda)\beta X_t + \lambda Y_{t-1} + u_t, u \sim MA(1)$$

Модель коррекции ошибок

Пример. Рассмотрим зависимость между продажами (Y) и затратами на рекламу (X)

$$Y_t = a_0 + b_0 X_t + b_1 X_{t-1} + \gamma Y_{t-1} + \varepsilon_t$$

Это уравнение часто переписывают в виде

$$\Delta Y_t = b_1 \Delta X_t - (1 - \gamma)(Y_{t-1} - a - bX_{t-1}) + \varepsilon_t$$

где $a = a_0 / (1 - \gamma)$, $b = (b_0 + b_1) / (1 - \gamma)$

Выражение в скобках $Y_{t-1} - a - bX_{t-1} = u_t$ представляет собой «остаток равновесия», $(1 - \gamma)$ – скорость коррекции

Векторная авторегрессия (VAR)

- VAR это система одновременных уравнений, которая состоит из одномерных моделей ARMA

$$Y_t = a_1 + b_{11}Y_{t-1} + b_{12}X_{t-1} + \varepsilon_{1t}$$

$$X_t = a_2 + b_{21}Y_{t-1} + b_{22}X_{t-1} + \varepsilon_{2t}$$

- $\varepsilon_1, \varepsilon_2$ - белые шумы, которые могут быть коррелированы

Преимущества VAR

- Модель может быть более экономной, включая меньше лагов
- Прогноз может быть точнее
- В модели не нужно уметь различать зависимые и независимые переменные
- Модель может быть оценена обычным МНК и оценки будут состоятельными, поскольку белый шум предполагается независимым от истории

Замечания о качестве эконометрических прогнозов

- При **неизменных внешних условиях**, когда эконометрическая модель и механизм порождения данных соответствуют друг другу прогноз, вычисленный как условное ожидание, будет оптимальным, т.е. несмещенным и эффективным.
- Различия прогноза и дальнейшей реализации процесса будут обусловлены только ошибкой, которую невозможно точно предсказать.
- Однако неизменность внешних условий в экономике обеспечить затруднительно, и в этом причина частой несостоятельности прогнозов.

Замечания и качества эконометрических прогнозов

- Теория прогнозирования, основанная на предположениях о стационарности процессов и постоянстве параметров моделей является неадекватной.
- С этими предположениями связана и гипотеза о нормальности, поскольку в нормальном законе распределения вероятностей дисперсия и математическое ожидание предполагаются неизменными.
- Однако использование моделей типа GARCH или стохастической волатильности позволяет отказаться от нереалистичных предположений и улучшить качество прогноза.



Спасибо за внимание!